



كلية العلوم و التقنيات
FACULTÉ DES SCIENCES ET TECHNIQUES

CNN Avancés : ResNet, EfficientNet & ConvNeXt

Note de Synthèse Scientifique

Résumé

Les CNN avancés représentent l'apogée du Deep Learning spatial avant l'ère des Transformers. Ce rapport dresse l'évolution architecturale depuis ResNet (qui a résolu le problème de la dégradation profonde) jusqu'à ConvNeXt. Nous présentons également les techniques modernes de régularisation et d'augmentation spatiale (mixup, cutmix). Nos expérimentations sur CIFAR-10 démontrent que le *fine-tuning* de modèles surpasse l'entraînement *from scratch*, et nous établissons un pont conceptuel fondamental avec les techniques de Boosting du module ML.

Amanetoullah Cheikh
Master 1 Intelligence Artificielle

Année Universitaire 2025–2026

Table des matières

1	Introduction et Motivation	3
1.1	Contexte Applicatif et Enjeux Régionaux	3
2	Positionnement Théorique et Évolution des CNN	3
2.1	La Révolution ResNet	3
2.2	Le Compound Scaling d'EfficientNet	3
2.3	De ConvNeXt à ConvNeXt V2 (Avancée numérique 2024)	3
2.4	Data Augmentation Moderne : Mixup	4
3	Étude Expérimentale et Benchmarking	4
3.1	Protocole et Plan d'Ablation	4
3.2	Résultats Comparatifs des Architectures	4
3.3	Analyse de l'Ablation des Augmentations	4
3.4	Visualisation des Cartes de Caractéristiques	5
4	Limites, Déploiement et Perspectives	5
5	Conclusion	5
	Usage des Assistants IA	6

1. Introduction et Motivation

1.1. Contexte Applicatif et Enjeux Régionaux

Les architectures convolutives avancées sont indispensables au traitement visuel. Dans le paysage numérique ouest-africain, elles trouvent une application directe dans l'imagerie satellitaire (cartographie et suivi en temps réel de la désertification pour l'OMVS) ou médicale décentralisée (diagnostics assistés par IA sur smartphone pour les zones rurales non pourvues en spécialistes).

L'enjeu technique majeur réside dans le développement de modèles robustes, capables de s'adapter aux contraintes locales de connectivité et de puissance de calcul, tout en maintenant un niveau d'exactitude élevé.

Analogie Centrale (Fil Conducteur Paire 3)

« La connexion résiduelle de ResNet ($y = \mathcal{F}(x) + x$) modifie la fonction d'apprentissage pour cibler le résidu identitaire. Cette logique est mathématiquement symétrique à la mise à jour des poids dans le Gradient Boosting ($f_{m+1}(x) = f_m(x) + \rho_m h_m(x)$ voir Rapport ML), prouvant que la correction d'erreur séquentielle est le principe moteur des algorithmes SOTA. »

2. Positionnement Théorique et Évolution des CNN

2.1. La Révolution ResNet

Le problème de dégradation profonde — où l'empilement excessif de couches dégrade l'exactitude d'apprentissage — a été résolu par He et al. [1] en introduisant la notion de blocs résiduels. Si la couche doit apprendre une identité, optimiser la fonction résiduelle $\mathcal{F}(x) \rightarrow 0$ est empiriquement et mathématiquement plus facile pour les gradients que d'optimiser une fonction brute $\mathcal{H}(x) \rightarrow x$.

2.2. Le Compound Scaling d'EfficientNet

EfficientNet [2] a prouvé empiriquement que la profondeur du réseau, la largeur des filtres (nombre de canaux) et la résolution spatiale des images ne doivent pas être modifiées de manière isolée ou arbitraire. Elles doivent être escaladées conjointement selon un ratio fixe déterminé par un coefficient composé (ϕ), optimisant drastiquement le nombre de FLOPS pour une enveloppe de calcul donnée.

2.3. De ConvNeXt à ConvNeXt V2 (Avancée numérique 2024)

ConvNeXt [3] a modernisé le ResNet standard en calquant sa topologie sur les choix de conception des Transformers (convolutions de type *depthwise* 7×7 , normalisation par couche). Cependant, cette architecture restait sujette à un phénomène de co-activation et de redondance des canaux lors des phases de pré-entraînement autosupervisé.

Pour surmonter cette limite, l'architecture **ConvNeXt V2 (2024)** [4] a introduit un mécanisme de **Normalisation Globale des Réponses** (*Global Response Normalization* - GRN) couplé à une stratégie d'auto-encodeur masqué (FCMAE). La couche GRN applique une compétition inter-canaux qui améliore la diversité des caractéristiques spatiales extraites,

consolidant la supériorité des structures convolutives pures face aux mécanismes d'attention gourmands en ressources matérielles.

2.4. Data Augmentation Moderne : Mixup

Pour empêcher la mémorisation pure du bruit et régulariser les frontières de décision, le *mixup* [5] interpole visuellement et mathématiquement les tenseurs d'entrée et leurs labels associés pendant l'entraînement :

$$\tilde{x} = \lambda x_i + (1 - \lambda)x_j \quad \text{et} \quad \tilde{y} = \lambda y_i + (1 - \lambda)y_j \quad (1)$$

où $\lambda \in [0, 1]$ suit une distribution $\text{Beta}(\alpha, \alpha)$.

3. Étude Expérimentale et Benchmarking

3.1. Protocole et Plan d'Ablation

Notre notebook PyTorch implémente le *Fine-tuning* de ResNet-18, EfficientNet-B0 et ConvNeXt-Tiny sur le jeu de données CIFAR-10. L'optimisation repose sur l'optimiseur AdamW couplé à un ordonnanceur de taux d'apprentissage de type CosineAnnealingLR.

3.2. Résultats Comparatifs des Architectures

Les performances empiriques recueillies à l'issue de l'entraînement complet mettent en évidence les disparités d'apprentissage entre les familles de modèles convolutifs.

Architecture	Params (M)	Best Acc (%)	Temps Total (s)
ResNet-18	11.2	72.18	235.7
EfficientNet-B0	4.0	61.97	360.0
ConvNeXt-Tiny	27.8	93.38	372.2

TABLE 1 – Comparatif des Architectures PyTorch — CIFAR-10

3.3. Analyse de l'Ablation des Augmentations

Afin de quantifier précisément l'impact de l'augmentation spatiale, un plan d'ablation a été mené sur la configuration de base de notre réseau de référence.

Configuration	Best Val Acc (%)	Temps Écoulé (s)
Baseline (sans augmentation)	72.38	236.9
Avec ajout du <i>mixup</i>	69.90	240.2

TABLE 2 – Analyse d'Ablation de la stratégie d'augmentation

3.4. Visualisation des Cartes de Caractéristiques

Pour valider l'impact de l'extraction spatiale et garantir l'interprétabilité interne du processus convolutif, les cartes de caractéristiques (*feature maps*) extraites des premières couches du réseau ont été matérialisées. On observe une spécialisation nette des filtres sur les structures de bas niveau (bords, textures locales et contrastes chromatiques).

4. Limites, Déploiement et Perspectives

- **Taille mémoire et localité spatiale** : Les CNN modernes à large noyau saturent rapidement la VRAM. L'activation de la précision mixte via `torch.cuda.amp.autocast()` est indispensable en production pour optimiser l'espace mémoire.
- **Inférence Edge AI** : Afin d'assurer le déploiement sur les appareils aux capacités matérielles limitées (Raspberry Pi, smartphones ou serveurs de terrain en Mauritanie), il est impératif d'exporter les graphes de calcul vers des formats d'inférence optimisés comme *TorchScript* ou *ONNX*.
- **L'Horizon des Modèles Hybrides Mamba (Rupture 2024–2025)** : Bien que les convolutions modernes soient optimisées pour la localité spatiale, elles peinent à modéliser les dépendances globales à longue distance sans une explosion du nombre de paramètres. Pour combler cette faille sans subir le coût quadratique des Transformers, les récents travaux se tournent vers les modèles d'espace d'états sélectifs (SSM) adaptés à la vision, à l'instar de **Vision Mamba (Vim)** [6]. Ces architectures hybrides CNN-Mamba ouvrent des perspectives critiques pour traiter des images satellitaires très haute résolution avec une complexité linéaire, une révolution technologique directe pour la télédétection subsaharienne.

5. Conclusion

Les CNN avancés ont prouvé que la construction minutieuse de l'architecture (topologie résiduelle) est aussi cruciale que la quantité de données elle-mêmes. L'alliance de ces extracteurs de caractéristiques profonds avec le Boosting tabulaire ouvre la voie aux pipelines hybrides hautement performants que nous exploiterons pour l'Examen Intégrateur.

Usage des Assistants IA

Déclaration d'Intégrité

Assistant	Tâche	Apport critique
Claude 3.5 Sonnet	Relecture académique et structure théorique.	Synthèse comparative initiale des architectures de réseaux profonds.
Gemini 3.1 Pro	Architecture globale, Ingénierie du code et Design.	Alignement thématique, intégration des métriques réelles du notebook, mise en forme des tableaux et indexation des références réelles vérifiées.

Références

- [1] K. He, X. Zhang, S. Ren, and J. Sun, "Deep residual learning for image recognition," in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016, pp. 770–778.
Disponible sur : <https://arxiv.org/abs/1512.03385>
- [2] M. Tan and Q. V. Le, "EfficientNet : Rethinking model scaling for convolutional neural networks," in *Proceedings of the 36th International Conference on Machine Learning (ICML)*, 2019, pp. 6105–6114.
Disponible sur : <https://arxiv.org/abs/1905.11946>
- [3] Z. Liu, H. Mao, C.-Y. Wu, C. Feichtenhofer, T. Darrell, and S. Xie, "A convnet for the 2020s," in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2022, pp. 11976–11986.
Disponible sur : <https://arxiv.org/abs/2201.03545>
- [4] S. Woo, S. Debnath, R. H. Rong, C. Liu, A. Nazaret, and S. Xie, "ConvNeXt V2 : Co-designing and scaling convnets with masked autoencoders," in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2023, pp. 561–571.
Disponible sur : <https://arxiv.org/abs/2301.00808>
- [5] H. Zhang, M. Cisse, Y. N. Dauphin, and D. Lopez-Paz, "mixup : Beyond empirical risk minimization," in *International Conference on Learning Representations (ICLR)*, 2018.
Disponible sur : <https://arxiv.org/abs/1710.09412>
- [6] L. Zhu, B. Liao, Q. Zhang, X. Wang, W. Liu, and X. Wang, "Vision Mamba : Efficient visual representation learning with bidirectional state space model," *arXiv preprint arXiv :2401.09417*, 2024.
Disponible sur : <https://arxiv.org/abs/2401.09417>