



كلية العلوم و التقنيات
FACULTÉ DES SCIENCES ET TECHNIQUES

Le Boosting : AdaBoost, XGBoost & LightGBM

Note de Synthèse Scientifique

Résumé

Le boosting constitue l'une des familles les plus performantes de méthodes d'ensemble en Machine Learning, reposant sur l'agrégation séquentielle d'apprenants faibles. Dans ce rapport, nous présentons rigoureusement AdaBoost, Gradient Boosting, XGBoost et LightGBM, depuis leurs fondements mathématiques jusqu'à leur application sur des données tabulaires (Adult Income). Nous montrons expérimentalement que XGBoost optimisé par recherche bayésienne (Optuna) surpasse les approches standards, et nous mettons en évidence la symétrie conceptuelle forte entre la correction séquentielle du boosting et la connexion résiduelle étudiée dans notre second rapport (ResNet).

Amanetoullah Cheikh
Master 1 Intelligence Artificielle

Année Universitaire 2025–2026

Table des matières

1	Introduction et Motivation	3
1.1	Contexte Applicatif et Enjeux Régionaux	3
2	Positionnement Théorique et Généalogie du Boosting	3
2.1	AdaBoost : Le Fondement de l'Ajustement Séquentiel	3
2.2	Gradient Boosting (GBM) : Généralisation par Descente Fonctionnelle	4
2.3	XGBoost : L'Optimisation par le Second Ordre et la Régularisation	4
2.4	LightGBM : L'Optimisation Scalable pour Grands Jeux de Données	5
3	Étude Expérimentale et Benchmarking	5
3.1	Protocole Expérimental	5
3.2	Résultats et Analyse du Benchmark	5
3.3	Interprétabilité via l'analyse SHAP	6
3.4	Analogie Conceptuelle : Boosting $\leftrightarrow$ ResNet	6
3.5	Analyse SHAP	6
4	Limites et Bonnes Pratiques	6
5	Conclusion	7
	Usage des Assistants IA	7

1. Introduction et Motivation

1.1. Contexte Applicatif et Enjeux Régionaux

Le Boosting repose sur un paradigme de décision collective : l'apprentissage séquentiel d'un ensemble d'apprenants faibles (*weak learners*), généralement des arbres de décision de faible profondeur, où chaque nouveau modèle est entraîné pour corriger explicitement les erreurs résiduelles commises par ses prédécesseurs.

Le succès des méthodes de Boosting, et plus particulièrement des *Gradient Boosted Decision Trees* (GBDT), repose sur leur efficacité exceptionnelle à traiter les données tabulaires hétérogènes. Contrairement aux réseaux de neurones profonds qui excellent en vision ou en langage, le Boosting demeure l'état de l'art pour les données structurées rencontrées massivement dans les secteurs clés de l'économie [1].

Dans le paysage numérique ouest-africain, ces modèles offrent des leviers stratégiques majeurs :

- **Inclusion Financière** : Optimisation du scoring de micro-crédit pour les populations non bancarisées, permettant une évaluation du risque plus fine que les méthodes statistiques classiques.
- **Secteur des Télécommunications** : Prévention de l'attrition (*churn*) et détection de fraudes en temps réel sur les flux massifs de données d'opérateurs comme Mauritel ou Mattel.
- **Souveraineté Alimentaire** : Prévision de la sécurité alimentaire et des rendements agricoles en couplant les données météorologiques locales à l'historique de pluviométrie de l'OMVS.

L'intérêt majeur de ces approches réside dans leur robustesse face aux données manquantes et leur capacité à capturer des relations non linéaires complexes sans nécessiter une infrastructure de calcul aussi lourde que celle du Deep Learning.

Analogie Centrale (Fil Conducteur Paire 3)

« Le boosting séquentiel apprend à corriger les erreurs résiduelles : $f_{m+1}(x) = f_m(x) + \rho_m h_m(x)$. La connexion résiduelle de ResNet (voir Rapport DL) fait exactement de même : $y = \mathcal{F}(x) + x$. Dans les deux paradigmes, le modèle apprend à corriger ses failles, et non à prédire la cible brute directement. »

2. Positionnement Théorique et Généalogie du Boosting

2.1. AdaBoost : Le Fondement de l'Ajustement Séquentiel

Développé par Freund et Schapire [2], AdaBoost (*Adaptive Boosting*) introduit le concept de modification dynamique des poids des données. L'algorithme cherche à minimiser une fonction de perte exponentielle.

À chaque itération t , une distribution de poids w_t est maintenue sur les N exemples d'apprentissage. La mise à jour de ces poids s'effectue selon la règle mathématique suivante :

$$w_{t+1,i} = \frac{w_{t,i}}{Z_t} \cdot \exp(-\alpha_t y_i h_t(x_i)) \quad (1)$$

Où chaque terme est défini comme suit :

- $w_{t,i}$ représente le poids associé à l'individu i à l'étape t . Un individu mal classé verra son poids augmenter à l'étape suivante.
- $y_i \in \{-1, 1\}$ correspond à la véritable étiquette de la classe pour l'exemple i .
- $h_t(x_i) \in \{-1, 1\}$ est la prédiction formulée par l'apprenant faible entraîné à l'étape t .
- $\alpha_t = \frac{1}{2} \ln \left(\frac{1-\epsilon_t}{\epsilon_t} \right)$ est le coefficient d'importance accordé au modèle h_t , calculé à partir de son taux d'erreur pondéré ϵ_t . Plus le modèle est précis, plus α_t est grand.
- Z_t est un facteur de normalisation garantissant que $\sum_{i=1}^N w_{t+1,i} = 1$.

Limitation : Bien que puissant, AdaBoost est très sensible au bruit et aux valeurs aberrantes (*outliers*) à cause de sa perte exponentielle qui sur-pénalise les erreurs extrêmes.

2.2. Gradient Boosting (GBM) : Généralisation par Descente Fonctionnelle

Proposé par Friedman [?], le *Gradient Boosting Machine* (GBM) résout les limites d'AdaBoost en transposant le problème dans le cadre de l'optimisation numérique. Au lieu d'ajuster des poids sur les individus, le GBM effectue une **descente de gradient fonctionnelle** dans l'espace des fonctions pour minimiser n'importe quelle fonction de perte différentiable $\mathcal{L}(y, f(x))$.

À chaque étape m , le nouveau modèle n'apprend pas directement sur les étiquettes y_i , mais sur les **pseudo-résidus** r_{im} , qui correspondent au gradient négatif de la perte par rapport aux prédictions actuelles :

$$r_{im} = - \left[\frac{\partial \mathcal{L}(y_i, f(x_i))}{\partial f(x_i)} \right]_{f(x)=f_{m-1}(x)} \quad (2)$$

La mise à jour globale du modèle composite devient alors :

$$f_m(x) = f_{m-1}(x) + \rho_m h_m(x) \quad (3)$$

Où $h_m(x)$ est l'arbre ajusté sur les pseudo-résidus r_{im} , et ρ_m est le pas d'optimisation (*learning rate*). Le GBM surpasse AdaBoost par sa flexibilité (gestion des régressions, classifications multiclasses via des pertes adaptées).

2.3. XGBoost : L'Optimisation par le Second Ordre et la Régularisation

XGBoost (*Extreme Gradient Boosting*) proposé par Chen et Guestrin [3] est une amélioration majeure et hautement optimisée du GBM traditionnel. Il introduit deux innovations théoriques cruciales :

1. **Développement de Taylor au second ordre :** Contrairement au GBM qui n'utilise que le gradient (premier ordre), XGBoost approxime la fonction de perte par une série de Taylor au second ordre, intégrant la **Hessienne** (dérivée seconde). La fonction d'objectif à minimiser à l'étape t devient :

$$\mathcal{L}^{(t)} \approx \sum_{i=1}^N \left[\mathcal{L}(y_i, f^{(t-1)}(x_i)) + g_i h_t(x_i) + \frac{1}{2} h_i h_t^2(x_i) \right] + \Omega(h_t) \quad (4)$$

Où $g_i = \frac{\partial \mathcal{L}(y_i, f^{(t-1)}(x_i))}{\partial f^{(t-1)}(x_i)}$ désigne le gradient, et $h_i = \frac{\partial^2 \mathcal{L}(y_i, f^{(t-1)}(x_i))}{\partial (f^{(t-1)}(x_i))^2}$ désigne la Hessienne. L'utilisation du second ordre permet une convergence beaucoup plus rapide et stable vers l'optimum.

2. **Régularisation explicite (Ω) :** Pour contrôler la complexité et éviter le surapprentissage (*overfitting*), XGBoost intègre directement des pénalités L_1 (α) et L_2 (λ) sur la structure des arbres dans l'objectif :

$$\Omega(h_t) = \gamma T + \frac{1}{2} \lambda \sum_{j=1}^T w_j^2 \quad (5)$$

Où T est le nombre de feuilles de l'arbre et w_j est le score d'importance de la feuille j .

2.4. LightGBM : L'Optimisation Scalable pour Grands Jeux de Données

Bien que XGBoost soit rigoureux, le calcul du gain d'information pour chaque découpe (*split*) sur de très grands ensembles de données devient prohibitif en temps et en mémoire. LightGBM [4] introduit deux ruptures algorithmiques pour surpasser XGBoost en vitesse et en scalabilité :

1. **GOSS (Gradient-based One-Side Sampling)** : Cette stratégie repose sur le constat que les instances ayant de petits gradients ont déjà une perte faible et sont donc bien entraînées. GOSS conserve toutes les instances ayant de grands gradients (qui contiennent le plus d'information pour corriger les erreurs) et effectue un sous-échantillonnage aléatoire sur les instances à petits gradients. Cela réduit drastiquement la taille des données à traiter sans altérer la précision du modèle.
2. **EFB (Exclusive Feature Bundling)** : Dans les données tabulaires, l'espace des descripteurs est souvent creux (*sparse*). EFB regroupe de manière non destructive les variables mutuellement exclusives (variables qui prennent rarement des valeurs non nulles en même temps) en une seule variable composite, réduisant ainsi la dimensionnalité globale et accélérant la construction des arbres.
3. **Croissance par feuilles (Leaf-wise)** : Contrairement à XGBoost qui construit ses arbres niveau par niveau (*Level-wise*), LightGBM fait croître l'arbre en choisissant la feuille qui maximise la réduction de la perte globale, produisant des arbres plus profonds et asymétriques, plus précis mais exigeant une régularisation stricte pour éviter le surapprentissage.

3. Étude Expérimentale et Benchmarking

Cette section présente les performances des algorithmes de Boosting sur le jeu de données réel **Adult Income** (prédiction de salaire > 50K\$). Ce dataset tabulaire hétérogène simule parfaitement une problématique de scoring bancaire ou de micro-crédit.

3.1. Protocole Expérimental

Le pipeline de traitement comprend un encodage robuste des variables catégorielles et une normalisation des variables numériques. Les modèles ont été évalués selon trois axes :

1. **Précision** : Mesurée par le F1-Score (macro) et l'aire sous la courbe ROC (AUC-ROC).
2. **Efficacité** : Temps d'entraînement nécessaire pour traiter les 32 561 instances.
3. **Optimisation** : Recherche d'hyperparamètres via l'optimisation bayésienne *Optuna* [?] sur 50 essais.

3.2. Résultats et Analyse du Benchmark

Les résultats obtenus mettent en évidence la supériorité des implémentations modernes (XGBoost et LightGBM) par rapport au Gradient Boosting standard de Scikit-Learn.

Analyse des performances :

- **Vitesse** : On observe une accélération massive ($\approx 38\times$) de XGBoost par rapport à Scikit-Learn, confirmant l'efficacité des implémentations optimisées pour le calcul parallèle.
- **Scalabilité** : LightGBM offre la meilleure précision brute avec un temps de calcul presque identique à XGBoost, validant l'intérêt de la stratégie GOSS.

Modèle	F1-macro	AUC-ROC	Temps (s)
sklearn GradientBoosting	0.8044	0.9228	8.12
XGBoost Classique	0.8075	0.9212	0.21
LightGBM	0.8124	0.9260	0.27
XGBoost + Optuna	0.8210	0.9315	0.21*

TABLE 1 – Benchmark des algorithmes de Boosting — Dataset Adult Income (*hors temps de recherche)

- **Apport d’Optuna** : L’optimisation bayésienne a permis de maximiser l’AUC-ROC en ajustant finement le taux d’apprentissage et la profondeur, surpassant les configurations par défaut.

3.3. Interprétabilité via l’analyse SHAP

Pour répondre aux exigences de transparence dans le secteur financier (cas d’usage du micro-crédit en Mauritanie), nous avons appliqué les valeurs de **SHAP** (*SHapley Additive exPlanations*). L’analyse montre que les variables "Age", "Marital Status" et "Education Num" sont les prédicteurs les plus influents. Cette interprétabilité permet de justifier un refus de crédit de manière éthique et légale.

3.4. Analogie Conceptuelle : Boosting ↔ ResNet

Conformément au lien entre Machine Learning et Deep Learning, cette étude met en évidence une symétrie mathématique forte. Dans le Boosting, chaque itération ajoute un arbre pour corriger le résidu :

$$F_m(x) = F_{m-1}(x) + \rho h_m(x) \quad (6)$$

Cette structure est identique à celle des **blocs résiduels (ResNet)** étudiés dans le module de Deep Learning :

$$y = x + \mathcal{F}(x) \quad (7)$$

Dans les deux cas, l’algorithme n’apprend pas une représentation complète, mais une **correction additive** (un résidu), facilitant ainsi l’optimisation de modèles très profonds.

3.5. Analyse SHAP

L’interprétabilité globale fournie par SHAP [?] révèle que l’âge et le statut marital sont les séparateurs majeurs de l’arbre de décision pour la classification des revenus.

4. Limites et Bonnes Pratiques

- **Surapprentissage** : Sensibilité extrême aux petits datasets ; l’*early stopping* est impératif.
- **Données déséquilibrées** : Ajuster `scale_pos_weight` plutôt que de faire du SMOTE.
- **Inadaptation visuelle** : Le Boosting échoue sur l’image pure ; d’où l’hybridation (Sujet Examen).

5. Conclusion

Le Boosting reste le souverain incontesté des bases de données tabulaires. Notre implémentation démontre la primauté de XGBoost optimisé et pose les bases conceptuelles (correction des résidus) qui seront visuellement exploitées dans la seconde partie de notre devoir sur ResNet.

Usage des Assistants IA

Déclaration d'Intégrité

Assistant	Tâche	Apport critique
Claude 3.5 Sonnet	Relecture académique et structure théorique.	Vérification croisée des formules mathématiques (Hessienne de XGBoost) et structuration initiale du document.
Gemini 3.1 Pro	Architecture globale, Ingénierie du code et Design.	Conception des notebooks (Filtrage dynamique Plant-Village, code <i>from scratch</i> AdaBoost/Mixup), design des présentations Beamer 16 :9, et alignement conceptuel (analogie AML/ADL).

Références

- [1] R. Shwartz-Ziv and A. Armon, "Tabular data : Deep learning is not all you need," *Information Fusion*, vol. 81, pp. 84–90, 2022.
Disponible sur : <https://doi.org/10.1016/j.inffus.2021.11.011>
- [2] Y. Freund and R. E. Schapire, "A decision-theoretic generalization of on-line learning and an application to boosting," *Journal of Computer and System Sciences*, vol. 55, no. 1, pp. 119–139, 1997.
Disponible sur : <https://doi.org/10.1006/jcss.1997.1504>
- [3] T. Chen and C. Guestrin, "XGBoost : A scalable tree boosting system," in *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 2016, pp. 785–794.
Disponible sur : <https://doi.org/10.1145/2939672.2939785>
- [4] G. Ke, Q. Meng, T. Finley, T. Wang, W. Chen, W. Ma, Q. Ye, and T.-Y. Liu, "LightGBM : A highly efficient gradient boosting decision tree," *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 30, pp. 3146–3154, 2017.
Disponible sur : <https://papers.nips.cc/paper/2017/hash/6449f44a102fde848669bdd9eb6b76fa-Abstract.html>