

Projet Intégrateur : Détection des Maladies des Plantes en Contexte Sahélien

Pipeline Hybride : ResNet-18, ACP & XGBoost

Examen Final – Master 1 IA

Module : Apprentissage Automatique & Deep Learning Avancé

Présenté par :

Amanetoullah Cheikh Mohamed Brahim

Année Universitaire :

2025 - 2026

L'intégralité des résultats présentés dans ce document sont strictement reproductibles via le notebook associé : `notebook_examen_pipeline_hybride.ipynb`

Table des matières

1	Introduction	2
2	Choix du Dataset & Pertinence en Mauritanie et en Afrique	2
2.1	Enjeux Sahéliens et Mauritaniens	2
3	Justification de l'Architecture (Deep Learning & Machine Learning)	2
3.1	Justification du Modèle DL (Transfer Learning)	2
3.2	Réduction de Dimensionnalité (ACP)	2
3.3	Choix du Méta-Modèle ML (XGBoost)	3
4	Validation Empirique et Comparaison	3
5	Explicabilité (XAI) et Perspectives Théoriques	3
5.1	Explicabilité Tabulaire et Spatiale (SHAP et Grad-CAM)	3
5.2	Perspectives : Incertitude et Bilan Énergétique	3
6	Conclusion	4

1. Introduction

L'agriculture intelligente s'impose aujourd'hui comme une nécessité vitale face aux défis climatiques et à la sécurité alimentaire mondiale. Ce projet d'étude détaille la conception d'un **pipeline hybride industriel** performant pour la détection des maladies des plantes, répondant aux exigences académiques de l'examen final de Master 1.

2. Choix du Dataset & Pertinence en Mauritanie et en Afrique

Le jeu de données **PlantVillage** [7] a été rigoureusement sélectionné pour sa pertinence directe avec notre contexte local.

2.1. Enjeux Sahéliens et Mauritaniens

L'utilisation de ce jeu de données, qui comprend des milliers d'images de tomates, maïs et pommes de terre, cible directement les cultures de subsistance essentielles en Afrique de l'Ouest et en Mauritanie [3].

- **Cultures Stratégiques** : Les maladies affectant la tomate (*Early blight*, *Late blight*) ou le maïs ont un impact dévastateur sur l'économie locale et la sécurité alimentaire en Mauritanie. La *Stratégie Nationale de l'Intelligence Artificielle en Mauritanie (2024-2029)* a récemment identifié l'agriculture intelligente et la prédiction des rendements comme une priorité nationale absolue pour la modernisation du pays [6].
- **Déploiement Adapté (Edge AI)** : La rareté des experts phytosanitaires sur le terrain justifie l'urgence d'applications mobiles basées sur l'IA. Notre approche hybride est pensée pour être frugale et déployable dans des environnements contraints (faible connectivité, terminaux à ressources limitées), une contrainte critique dans les zones agricoles d'Afrique subsaharienne [1].

3. Justification de l'Architecture (Deep Learning & Machine Learning)

3.1. Justification du Modèle DL (Transfer Learning)

Afin de doter le pipeline d'un extracteur de caractéristiques visuelles puissant sans nécessiter des semaines de calculs, nous avons exploité le **Transfer Learning** via l'architecture **ResNet-18** [4].

- **Principe Théorique** : Les travaux fondamentaux [8] prouvent que les premières couches convolutives capturent des motifs universels (bords, textures). Nous avons *fine-tuné* ce modèle (pendant 2 epochs, soit 280 minutes) sur nos 22 076 images locales pour spécialiser ses dernières couches aux pathologies foliaires.
- **Pourquoi ResNet-18?** Face à des modèles lourds comme VGG-16, ResNet-18 offre des connexions résiduelles évitant la disparition du gradient, tout en restant extrêmement compact. L'activation de sa couche finale génère un vecteur très informatif de **512 dimensions** par image. L'accuracy de validation obtenue lors du fine-tuning a atteint 97.97%.

3.2. Réduction de Dimensionnalité (ACP)

Bien que performantes, 512 dimensions posent un risque de "fléau de la dimension" pour les classifieurs Machine Learning aval. Nous avons appliqué une **Analyse en Composantes**

Principales (ACP) [5].

- **Résultat empirique** : Le modèle a réussi à compresser l'information en conservant **95% de la variance globale avec seulement 85 composantes principales**.
- **Justification vs UMAP** : Contrairement à des méthodes non linéaires de réduction (comme t-SNE ou UMAP) souvent limitées à la visualisation, l'ACP offre une projection linéaire déterministe, rapide et parfaitement adaptée pour de l'inférence en temps réel sur le terrain.

3.3. Choix du Méta-Modèle ML (XGBoost)

Pour classer les 85 composantes générées par l'ACP, le choix s'est porté sur **XGBoost** [2].

1. **Puissance et Régularisation** : XGBoost intègre nativement une régularisation L1/L2 qui limite le surapprentissage sur les représentations latentes de l'ACP.
2. **Configuration optimisée** : Le modèle a été configuré avec 200 estimateurs, une profondeur maximale de 6, et la méthode de construction d'arbres hist pour garantir un entraînement accéléré.

4. Validation Empirique et Comparaison

Le pipeline hybride complet (Image → ResNet-18 → ACP → XGBoost) a été testé sur un jeu de données indépendant composé de 5 520 images recouvrant 15 classes différentes.

Performances Globales sur le Jeu de Test

- **Précision Globale (Test Accuracy)** : 98.62 %
- **F1-Score (Macro / Weighted)** : 0.99

Ces résultats, directement extraits de notre matrice de confusion et rapport de classification, prouvent que l'hybridation est exceptionnellement robuste et compétitive face aux modèles 100% Deep Learning, tout en étant plus transparente.

5. Explicabilité (XAI) et Perspectives Théoriques

5.1. Explicabilité Tabulaire et Spatiale (SHAP et Grad-CAM)

Pour qu'un modèle soit déployé en milieu agricole, il doit être explicable. Notre notebook intègre deux couches de transparence :

- **SHAP (Shapley Additive exPlanations) [?]** : L'analyse SHAP appliquée au modèle XGBoost confirme que les premières composantes de l'ACP concentrent l'essentiel du pouvoir prédictif. Le modèle s'appuie bien sur les caractéristiques mathématiques dominantes extraites par ResNet.
- **Grad-CAM [?]** : Pour s'assurer que le CNN ne subit pas de biais lié à l'arrière-plan (ex : fond de laboratoire), les heatmaps Grad-CAM générées montrent visuellement que l'activation des neurones cible précisément la zone nécrosée de la feuille.

5.2. Perspectives : Incertitude et Bilan Énergétique

Dans un cadre de déploiement réel en Mauritanie, d'autres dimensions académiques seraient à considérer pour améliorer encore le pipeline :

- **Incertitude (MC-Dropout)** : Évaluer la confiance du modèle face à des maladies non vues pourrait s'effectuer en intégrant Monte-Carlo Dropout.
- **Équité des données (Fairness)** : Bien que nous utilisions l'augmentation de données classique via DataLoader, l'utilisation de méthodes avancées (MixUp, CutMix) serait une perspective intéressante pour renforcer la robustesse face aux environnements extérieurs fortement bruités.
- **Sobriété Énergétique** : L'architecture hybride présente un avantage théorique fort sur les gros modèles Transformers ou CNN très profonds, car le passage dans le réseau (extraction seule) puis dans l'ACP et XGBoost consomme moins de VRAM et d'énergie lors de l'inférence.

6. Conclusion

En intégrant les enjeux spécifiques à l'Afrique et au contexte sahélien mauritanien, ce projet démontre la viabilité d'un système intelligent et économe. La combinaison d'un extracteur profond (ResNet-18), d'une réduction mathématique (ACP) et d'un classifieur puissant (XGBoost) a permis d'atteindre une précision remarquable de 98.62%. Grâce à SHAP et Grad-CAM implémentés dans notre solution, ce pipeline est non seulement très précis, mais aussi totalement interprétable et prêt à répondre aux problématiques phytosanitaires locales.

Références

- [1] Emmanuel A Abioye, Oliver Hensel, Travis Esau, and Olatunji Elisha. Smart agriculture in Sub-Saharan Africa : A systematic review of AI-based crop disease detection. *Computers and Electronics in Agriculture*, 218 :108723, 2024. <https://doi.org/10.1016/j.compag.2024.108723>.
- [2] Tianqi Chen and Carlos Guestrin. XGBoost : A scalable tree boosting system. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 785–794, 2016. <https://arxiv.org/abs/1603.02754>.
- [3] FAO/CILSS. Perspectives agricoles et sécurité alimentaire au Sahel et en Afrique de l'Ouest. *Rapport conjoint FAO-CILSS*, 2024. <https://www.fao.org/publications/home/fr>.
- [4] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 770–778, 2016. <https://arxiv.org/abs/1512.03385>.
- [5] Ian T Jolliffe and Jorge Cadima. Principal component analysis : a review and recent developments. *Philosophical Transactions of the Royal Society A*, 374(2065) :20150202, 2016. <https://royalsocietypublishing.org/doi/10.1098/rsta.2015.0202>.
- [6] Ministère de la Transition Numérique, de l'Innovation et de la Modernisation de l'Administration. Stratégie nationale de l'intelligence artificielle en Mauritanie (2024-2029). Technical report, Gouvernement de la République Islamique de Mauritanie, 2024. <https://www.numerique.gov.mr/>.
- [7] Sharada P Mohanty, David P Hughes, and Marcel Salathé. Using deep learning for image-based plant disease detection. *Frontiers in Plant Science*, 7 :1419, 2016. <https://www.frontiersin.org/articles/10.3389/fpls.2016.01419/full>.
- [8] Jason Yosinski, Jeff Clune, Yoshua Bengio, and Hod Lipson. How transferable are features in deep neural networks? *Advances in Neural Information Processing Systems (NeurIPS)*, 27 :3320–3328, 2014. <https://papers.nips.cc/paper/5549-how-transferable-are-features-in-deep-neural-networks>.